

# Formulario Estadística

Abel Doñate Muñoz

## Contents

<b>1</b>	<b>Cosas útiles</b>	<b>3</b>
<b>2</b>	<b>Intro</b>	<b>3</b>
<b>3</b>	<b>Tema 3</b>	<b>4</b>
<b>4</b>	<b>Estimación por intervalos</b>	<b>5</b>
<b>5</b>	<b>Contrastes de hipótesis</b>	<b>5</b>
<b>6</b>	<b>Modelo lineal normal</b>	<b>6</b>

Tabla de distribuciones discretas

<i>Modelo</i>	$p(X = k)$	$E[X]$	$Var[X]$	$G_X(z)$
<b>Bernoulli</b> $\sim Be(p)$	$\begin{cases} p(X = 1) = p \\ p(X = 0) = 1 - p \end{cases}$	$p$	$p(1 - p)$	$(1 - p) + pz$
<b>Binomial</b> $\sim Bin(N, p)$	$\binom{N}{k} p^k (1 - p)^{N-k}$	$Np$	$Np(1 - p)$	$((1 - p) + pz)^N$
<b>Uniforme</b> $\sim U(1, N)$	$\frac{1}{N}$	$\frac{N+1}{2}$	$\frac{N^2 - 1}{12}$	$\frac{1}{N} \frac{z(z^N - 1)}{z - 1}$
<b>Poisson</b> $\sim Po(\lambda)$	$\frac{\lambda^k}{k!} e^{-\lambda}$	$\lambda$	$\lambda$	$e^{\lambda(z-1)}$
<b>Geométrica</b> $\sim Geom(p)$	$p(1 - p)^{k-1}$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$	$\frac{pz}{1 - (1 - p)z}$
<b>Binomial negativa</b> $\sim BinN(r, p)$	$\begin{cases} 0 & \text{si } k < r \\ \binom{k-1}{r-1} p^r (1 - p)^{k-r} & \text{si } k \geq r \end{cases}$	$\frac{r}{p}$	$r \frac{1 - p}{p^2}$	$\left( \frac{pz}{1 - (1 - p)z} \right)^r$

Tabla de distribuciones continuas

<i>Modelo</i>	$f_X(x)$	$E[X]$	$Var[X]$	$G_X(z)$
<b>Uniforme</b> $\sim U(a, b)$	$\frac{1}{b-a} \mathbb{I}_{[a,b]}$	$\frac{b+a}{2}$	$\frac{(b-a)^2}{12}$	$1 \text{ en } t = 0, \frac{e^{ibt} - e^{iat}}{it(b-a)}$
<b>Exponencial</b> $\sim Exp(\lambda)$	$\lambda e^{-\lambda x}, x \geq 0, \lambda > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\frac{\lambda}{\lambda - it}$
<b>Normal</b> $\sim N(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	$\mu$	$\sigma^2$	$e^{i\mu t - \frac{\sigma^2 t^2}{2}}$
<b>Gamma</b> $\sim Gamma(\lambda, \tau)$	$\frac{\lambda^\tau}{\Gamma(\tau)} x^{\tau-1} e^{-\lambda x}, x > 0, \lambda, \tau > 0$	$\frac{\tau}{\lambda}$	$\frac{\tau}{\lambda^2}$	$\left(1 - \frac{it}{\lambda}\right)^{-\tau}$
<b>Beta</b> $\sim Beta(\alpha, \beta)$	$\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, x \in [0, 1]$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$	Sin forma sencilla
<b>Weibull</b> $\sim Weibull(\alpha, \beta)$	$\frac{\alpha}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} e^{-(x/\beta)^\alpha}, x, \alpha, \beta > 0$	$\beta \Gamma\left(1 + \frac{1}{\alpha}\right)$	$\beta^2 \left[ \Gamma\left(1 + \frac{2}{\alpha}\right) - \Gamma^2\left(1 + \frac{1}{\alpha}\right) \right]$	$\sum_{k \geq 0} \frac{(it)^k \beta^k}{k!} \Gamma\left(1 + \frac{k}{\alpha}\right)$
<b>Cauchy</b> $\sim Cauchy(\theta, \gamma)$	$\frac{1}{\pi\gamma} \frac{1}{1 + \left(\frac{x-\theta}{\gamma}\right)^2}, \gamma > 0$	No definida	No definida	$e^{\theta it - \gamma t }$
$\chi_p^2$	$\frac{1}{\Gamma(p/2)2^{p/2}} x^{\frac{p}{2}-1} e^{-\frac{x}{2}}, x > 0, p \in \mathbb{N}$	$p$	$2p$	$(1 - 2it)^{-\frac{p}{2}}$
<b>Doble expon</b> $\sim DobExp(\mu, \gamma)$	$\frac{1}{2\gamma} e^{-\frac{ x-\mu }{\gamma}}, \gamma > 0$	$\mu$	$2\gamma^2$	$\frac{e^{\mu it}}{1 + \gamma^2 t^2}$
<b>Lognormal</b> $\sim LogN(\mu, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} \frac{1}{x} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}, x, \sigma > 0$	$e^{\mu + \frac{\sigma^2}{2}}$	$e^{2(\mu + \sigma^2)} - e^{2\mu + \sigma^2}$	Sin forma sencilla

# 1 Notación

$\tilde{X}$  representa un vector, mientras que  $\bar{X}$  representa la media.

Para los intervalos de confianza tomamos  $t_\beta$  como el  $t$  tal que tiene una probabilidad de  $\beta$  a la derecha.

## 2 Intro

**Proposition.** Sea  $\tilde{X}$  absolutamente continua con  $f_{\tilde{X}}(x_1, \dots, x_n)$ . Sea  $g: \mathbb{R}^n \rightarrow \mathbb{R}^n \in \mathcal{C}^1$  biyectiva. Si  $g(\tilde{X}) = \tilde{Y}$  encontramos  $f_{\tilde{Y}}$  de la siguiente forma:

Sea  $h := g^{-1}$ :

$$f_{\tilde{Y}}(y_1, \dots, y_n) = f_{\tilde{X}}(h(y_1, \dots, y_n)) |J_h(y_1, \dots, y_n)|$$

**Definition** (Varianza, covarianza y correlación).

$$\begin{aligned} s_x^2 &= \frac{1}{N} \sum (x_i - \bar{x}_N)^2 \\ s_{xy} &= \frac{1}{N} \sum (x_i - \bar{x}_N)(y_i - \bar{y}_N) \\ r_{xy} &= \frac{s_{xy}}{s_x s_y} \end{aligned}$$

**Definition** (Parámetros a estimar).

$$X \sim F \Rightarrow \theta = \Phi(F)$$

**Definition** (Estimador).  $X_1, \dots, X_n$

$$\hat{\theta} = T(X_1, \dots, X_n)$$

**Definition** (Función de distribución empírica).

$$F_n(x) = \frac{1}{n} \sum I_{(-\infty, x]}(x_i)$$

**Theorem.**  $X_1, \dots, X_n, x \in \mathbb{R}$

1.  $E(F_n(x)) = F(x)$ ,  $Var(F_n(x)) = \frac{1}{n} F(x)(1-F(x))$
2.  $F_n(x) \rightarrow F(x)$  casi seguro
3.  $\frac{\sqrt{n}(F_n(x)-F(x))}{\sqrt{F(x)(1-F(x))}} \rightarrow N(0,1)$  en distribución
4.  $\frac{\sum(x_i - \mu)}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \rightarrow N(0,1)$ , TCL

**Theorem** (Glivenko-Cantelli).  $\{X_n\}$  *va iid*

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \rightarrow 0$$

**Theorem.** Sean  $x_1, \dots, x_n$ ,  $S^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$  la varianza muestral

1.  $\min_a \sum (x_i - a)^2 = \sum (x_i - \bar{x})^2$
2.  $(n-1)S^2 = \sum (x_i - \bar{x})^2 = \sum x_i^2 - n\bar{x}^2$

**Definition** (Media muestral).  $\bar{X} = \frac{1}{n} \sum X_i$

**Definition** (Varianza muestral).  $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$

**Theorem.**  $X$  con media  $\mu$  y varianza  $\sigma^2$

1.  $E(\bar{X}) = \mu$
2.  $V(\bar{X}) = \frac{\sigma^2}{n}$

$$3. E(S^2) = \sigma^2$$

**Proposition.**

$$N(\mu_1, \sigma_1^2) + N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

**Theorem.**

$$\psi_{\bar{X}}(t) = (\psi_X\left(\frac{t}{n}\right))^n$$

**Definition** (Distribución  $\chi_k^2$ ). Sea  $X_i \sim N(0,1)$

$$\chi_k^2 = \sum X_i^2 = \Gamma\left(\frac{n}{2}, \frac{1}{2}\right)$$

**Proposition.** Sea  $\tilde{X} \sim N_p(\tilde{\mu}, \Sigma)$

$$\tilde{Y} = A\tilde{X} \sim N_p(A\tilde{\mu}, A\Sigma A^t)$$

**Proposition.** Sea  $\tilde{X} \sim N_p(\tilde{\mu}, \Sigma)$

$$(\tilde{X} - \tilde{\mu})^t \Sigma^{-1} (\tilde{X} - \tilde{\mu}) \sim \chi_p^2$$

**Theorem** (Fisher).  $X_i \sim N(\mu, \sigma^2)$  *va iid entonces*

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)}{\sigma^2} S^2 \sim \chi_{n-1}^2 \quad \text{indep}$$

**Definition** (t de Student). Sean  $X \sim N(0,1)$ ,  $Y \sim \chi_r^2$  *indep*

$$T = \frac{X}{\sqrt{\frac{Y}{r}}} \sim t_r, \quad f_T(t) = \frac{\Gamma(\frac{r+1}{2})}{\sqrt{\pi r} \Gamma(\frac{r}{2})} \left(1 + \frac{t^2}{r}\right)^{-\frac{r+1}{2}}$$

$$\text{Si } r > 1 \Rightarrow E(T) = 0, \text{ si } r > 2 \Rightarrow Var(T) = \frac{r}{r-1}$$

**Proposition.** Sean  $X_i \sim N(\mu, \sigma)$  *va iid*

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}$$

**Definition** (Distribución F). Sean  $X \sim \chi_r^2$ ,  $Y \sim \chi_s^2$  *indep*

$$F = \frac{X/r}{Y/s} \sim F_{r,s}, \quad f_F(t) = \frac{r\Gamma((r+s)/2)}{s\Gamma(r/2)\Gamma(s/2)} \frac{(xr/s)^{r/2-1}}{(1+xr/s)^{(r+s)/2}}$$

$$s > 2 \Rightarrow E(F) = \frac{s}{s-2}, \quad s > 4 \Rightarrow Var(F) = \frac{2s^2(r+s-2)}{r(s-2)^2(s-4)}$$

**Proposition.**  $F^{-1} \sim F_{s,r}$ ,  $T^2 \sim F_{1,r}$

Sean  $X_1, \dots, X_n \sim N(\mu_1, \sigma_1)$ ,  $Y_1, \dots, Y_m \sim N(\mu_2, \sigma_2)$  *va iid*

$$\frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F_{n-1, m-1}$$

**Definition** (Localización y escala).

$$X = \mu + \sigma Z, \quad f(x|\mu, \sigma) = \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right)$$

- $Z \sim f(x) \iff X = \mu + \sigma Z \sim f(x|\mu, \sigma)$
- $X \sim f(x|\mu, \sigma) \iff \frac{X-\mu}{\sigma} \sim f(x)$

**Definition** (Estimador plug-in).

$$F_n(x) = \frac{1}{n} \sum I_{(-\infty, x]}(X_i) \Rightarrow \hat{\theta}_n = \Phi(F_n)$$

**Definition** (Método de los momentos). Sea  $\mu_k = E(X^k)$  y que existe una biyección

$$\mu_i = g_i(\theta_1, \dots, \theta_k) \iff \theta_i = h_i(\mu_1, \dots, \mu_k)$$

entonces  $\hat{\theta}_i = h_i(m_1, \dots, m_k)$  con  $m_j = \frac{1}{n} \sum X^j$

**Definition** (Estimador máximo verosímil).

$$l(\theta, \tilde{x}) = \ln L(\theta, \tilde{x}) = \ln f_{\tilde{x}}(\theta) \Rightarrow \hat{\theta} = \arg \max_{\theta} l(\theta, \tilde{x})$$

**Theorem** (Principio de invariancia).  $\psi = \Psi(\theta)$  con  $\Psi$  biyectiva  $\Rightarrow \hat{\psi}_{ML} = \Psi(\hat{\theta}_{ML})$ .

**Definition** (Kullback-Leiber).

$$D_{K,L}(f\|g) = \int_S \ln \left( \frac{f(x)}{g(x)} \right) f(x) dx \geq 0$$

$$E_f(\ln(f(X))) \geq E_f(\ln(g(X)))$$

**Theorem** (Bayes).

$$f_{X|Y=y}(x) = \frac{P(Y=y|X=x)f_X(x)}{P(Y=y)}$$

### 3 Tema 3

**Definition.**  $T_n(X_1, \dots, X_n)$  estadístico. Llamamos **distribución de muestreo** a la distribución de  $T_n$  y **error estándar** a la desviación estándar de  $T_n$ .

**Definition** (Sesgo).  $B(\hat{\theta}) = E(\hat{\theta}) - \theta$

**Definition** (ECM).  $ECM(\hat{\theta}) = E((\hat{\theta} - \theta)^2) = (B(\hat{\theta}))^2 + Var(\hat{\theta})$

**Definition.** Un estimador  $W(\tilde{X})$  de  $\theta_F$  es **inadmisible** si  $\exists V(\tilde{X}) : ECM_F(W, \theta_F) \geq ECM_F(V, \theta_F) \forall F \in \mathcal{F}$ ,  $\exists F_0 : ECM_{F_0}(W, \theta_{F_0}) > ECM_{F_0}(V, \theta_{F_0})$ .

**Definition** (Eficiencia relativa de W respecto V).

$$ER(\theta_F, W, V) = \frac{Var_F(V)}{Var_F(W)} = \frac{1/Var_F(W)}{1/Var_F(V)} = \frac{Precision(W)}{Precision(V)}$$

**Theorem** (Cramer-Rao). Sea  $W(\tilde{X})$  un estimador insesgado para  $\tau(\theta)$

$$Var(W(\tilde{X})) \geq \frac{\left( \frac{d\tau(\theta)}{d\theta} \right)^2}{E \left[ \left( \frac{\partial}{\partial \theta} \log f(\tilde{X}|\theta) \right)^2 \right]}$$

**Definition** (Información de Fisher).

$$I_{\tilde{x}}(\theta) = E_{\theta} \left[ \left( \frac{\partial}{\partial \theta} \ln f_{\tilde{x}} \right)^2 \right] = Var_{\theta} \left( \frac{\partial}{\partial \theta} \ln f_{\tilde{x}} \right)$$

$$I_{\tilde{x}}(\theta) = -E_{\theta} \left[ \frac{\partial^2}{\partial \theta^2} \ln f_{\tilde{x}} \right]$$

**Proposition.**  $I_{\tilde{x}}(\theta) = nI_{x_i}(\theta)$

**Theorem** (Alcanzar CR).  $W(\tilde{X})$  estimador de  $\tau(\theta)$  alcanza CR  $\iff$

$$\frac{\partial}{\partial \theta} \ln f_{\tilde{x}} = a(\theta)(W(\tilde{X}) - \tau(\theta))$$

$$\iff f_{\tilde{x}}(\tilde{X}) = u(\tilde{X})h(\theta) \exp(W(\tilde{X})k(\theta))$$

**Definition** (Estadístico suficiente).  $\frac{f(\tilde{x}|\theta)}{q(T(\tilde{x})|\theta)}$  no dep. de  $\theta$

**Theorem** (Factorización).  $T(\tilde{X})$  suficiente  $\iff$

$$f(\tilde{x}; \theta) = g(T(\tilde{x}); \theta)h(\tilde{x})$$

**Definition** (Estadístico suficiente minimal).  $T(X)$  suficiente es minimal  $\iff$  para cualquier otro  $S(X)$  suficiente,  $T(X)$  es función de  $S(X)$

**Theorem.**  $f(\tilde{x}|\theta)$  la verosimilitud. Si

$$\frac{f(\tilde{x}|\theta)}{f(\tilde{y}|\theta)} = g(\tilde{x}, \tilde{y}, \theta) \iff T(\tilde{x}) = T(\tilde{y})$$

Entonces  $T(x)$  es suficiente minimal

**Definition** (Compleitud). Si

$$E_{\theta}[g(T)] = 0 \forall \theta \Rightarrow P(g(T) = 0) = 1 \forall \theta$$

entonces decimos que  $T$  es completo

**Proposition.** suficiente completo  $\Rightarrow$  suficiente minimal (el recíproco no es cierto)

**Theorem.**  $X$  familia exponencial

$$f(x|\theta) = h(x)c(\theta) \exp\left(\sum g_j(\theta)t_j(x)\right)$$

entonces el estadístico  $T(\tilde{X}) = (T_1(\tilde{x}), \dots, T_k(\tilde{X}))$ , donde  $T_j(\tilde{X}) = \sum t_j(X_i)$  es suficiente completo

**Theorem** (Pitman-Koopman-Darmois). Si el soporte de las distribuciones no depende de  $\theta$  y  $\exists$  un estadístico suficiente, el modelo es de una familia exponencial.

**Theorem** (Rao-Blackwell).  $T(\tilde{X})$  suficiente  $W(\tilde{X})$  insesgado de  $\tau(\theta)$ . Definimos  $W_T = E_{\theta}(W|T)$

1.  $W_T$  función únicamente de  $T(X)$

2.  $E_{\theta}(W_T) = \tau(\theta) \forall \theta$

3.  $Var_{\theta}(W_T) \leq Var_{\theta}(W) \forall \theta$

**Proposition.** Si  $W$  es el mejor estimador insesgado de  $t(\theta)$  y su varianza es finita, entonces  $W$  es único

**Definition** (Ruido blanco). Estadístico  $U$  tal que  $E_{\theta}(U) = 0 \forall \theta$

**Theorem.**  $W$  estimador insesgado de  $\tau(\theta) \forall \theta$ .  $W$  UMVUE  $\iff W$  incorrelado con todos los ruidos blancos.

**Proposition.**  $W$  insesgado de  $\tau(\theta)$  UMVUE  $\iff$  es función del estadístico minimal suficiente  $T$  para  $\theta$  y está incorrelado con los estimadores insesgados de  $\theta$  que sean función del estadístico  $T$  minimal suficiente para  $\theta$

**Theorem** (Lehmann-Scheffé).  $T(\tilde{X})$  suficiente y completo para  $\theta$ ,  $W(\tilde{X})$  estimador insesgado cualquiera de  $\tau(\theta)$ , entonces

$$W_T(\tilde{X}) = E_{\theta}(W|T(\tilde{X}))$$

es UMVUE de  $\tau(\theta)$ . Si la variancia es finita  $\forall \theta \Rightarrow W_T$  es único

**Proposition.**  $T(\tilde{X})$  suficiente y completo

1.  $W$  insesgado de  $\tau(\theta)$  y función de  $T$ , entonces  $W$  es UMVUE

2. Cualquier función de  $T$  que tenga esperanza finita es el UMVUE de su esperanza.

**Definition** (Consistencia en probabilidad). La sucesión  $\hat{\theta}_n = T(\tilde{X})$  es consistente si

$$\lim P(|\hat{\theta}_n - \theta| < \varepsilon) = 1 \quad (\iff \lim \hat{\theta}_n = \theta \text{ en probabilidad})$$

**Theorem.** Si  $\hat{\theta}_n$  verifica

- $\lim \text{Var}(\hat{\theta}_n) = 0 \quad \forall \theta$
- $\lim B_\theta(\hat{\theta}_n; \theta) = 0 \quad \forall \theta$

entonces  $\hat{\theta}_n$  es consistente en media cuadrática y en probabilidad

**Theorem.**  $\hat{\theta}_n$  consistente en probabilidad

1.  $a_n \rightarrow 1, b_n \rightarrow 0 \Rightarrow (a_n \hat{\theta}_n + b_n)$  consistente
2.  $g$  continua  $\Rightarrow g(\hat{\theta}_n)$  consistente para  $g(\theta)$
3.  $\hat{\delta}_n$  estimadores consistentes para  $\delta, g(\theta, \delta)$  continua  $\Rightarrow g(\hat{\theta}_n, \hat{\delta}_n)$  consistente para  $g(\theta, \delta)$

**Definition** (Normalidad asintótica).  $\hat{\theta}_n$  la presenta si  $\exists v_n(\theta) \rightarrow 0$  no negativos tal que

$$\frac{(\hat{\theta}_n - \theta)}{\sqrt{v_n(\theta)}} \rightarrow_D N(0, 1) \Rightarrow \hat{\theta}_n \sim AN(\theta, v_n(\theta))$$

**Definition** (Eficiencia relativa asintótica).  $T_n(\tilde{X}), S_n(\tilde{X})$  estimadores de  $\theta$  asintoticamente normales varianza del orden  $1/n$

$$\begin{aligned} \sqrt{n}(T_n(\tilde{X}) - \theta) &\rightarrow_D N(0, \sigma_T^2(\theta)) \\ \sqrt{n}(S_n(\tilde{X}) - \theta) &\rightarrow_D N(0, \sigma_S^2(\theta)) \\ ARE(\theta, S_n, T_n) &= \frac{\sigma_T^2(\theta)}{\sigma_S^2(\theta)} \end{aligned}$$

**Theorem** (Slutzky).  $X_n \rightarrow_D X, Y_n \rightarrow_P a$ . Entonces

1.  $X_n + Y_n \rightarrow_D X + a$
2.  $X_n Y_n \rightarrow_D aX$
3.  $g(x, y)$  continua  $\Rightarrow g(X_n, Y_n) \rightarrow_D g(x, y)$

**Theorem** (Método delta).  $a_n \rightarrow \infty$

$$\begin{aligned} a_n(\hat{\theta}_n - \theta) &\rightarrow_D N(0, \sigma^2(\theta)) \Rightarrow \\ &\Rightarrow a_n(g(\hat{\theta}_n) - g(\theta)) \rightarrow_D N(0, (g'(\theta))^2 \sigma^2(\theta)) \end{aligned}$$

Estimador de momentos:  $\hat{\theta}_n = \bar{x}_n, \theta = E[X] \Rightarrow a_n = \sqrt{n}, \sigma^2(\theta) = \text{Var}(X)$

**Theorem.** Si se verifican

1. Distinta  $\theta \rightarrow$  distinta distribución ( $\theta$  identificable)
2.  $\{x : f(x|\theta) > 0\}$  es el mismo  $\forall \theta$
3.  $E_{\theta_0}(\log(\frac{f(X|\theta)}{f(X|\theta_0)}))$  existe  $\forall \theta, \theta_0$
4.  $\Theta$  es un abierto
5.  $\frac{\partial f(x|\theta)}{\partial \theta}$  es continua en  $\theta$

entonces si 1, 2, y 3:

$$E_{\theta_0} \left[ \log \left( \frac{L(\theta|X_n)}{L(\theta_0|X_n)} \right) \right] < 0, \lim P_{\theta_0} \{L(\theta_0|X_n) > L(\theta|X_n)\} = 1$$

$$\text{Si además 4 y 5: } \frac{\partial}{\partial \theta} \log L(\theta|X_n) = 0$$

**Theorem.** Si además  $\exists \frac{\partial^3}{\partial \theta^3}$  acotada por  $K(x)$  tal que  $E_\theta(K(X)) \leq k, \theta_n$  raíces del score:  $\hat{\theta}_n \rightarrow_P \theta_0$ , entonces

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \rightarrow_D N(0, \frac{1}{I_X(\theta_0)}), \quad X \sim f(x; \theta_0)$$

**Theorem.** Los estimadores

$$O_n = -\frac{\partial^2 \log L(\theta|X_n)}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n}, \quad E_n = I_{X_n}(\hat{\theta}_n)$$

divididos por  $n$  son estimadores consistentes de  $I_X(\theta_0)$

## 4 Estimación por intervalos

**Definition** (Estimador por intervalos).  $[L(\tilde{X}), U(\tilde{X})]$

**Definition** (Probabilidad de cobertura).  $P_\theta(\theta \in [L(\tilde{X}), U(\tilde{X})])$

**Definition** (Coeficiente de cobertura (confianza)).  $\inf_\theta P_\theta(\theta \in [L(\tilde{X}), U(\tilde{X})])$

**Definition** (Intervalo de confianza).  $IC_{1-\alpha}(\theta)$

**Proposition.**  $IC_{1-\alpha}$  de  $\theta$  es  $[L(X), U(X)] \Rightarrow IC_{1-\alpha}$  de  $\tau(\theta)$  es  $[\tau(L(X)), \tau(U(X))]$  si es creciente (al revés si decreciente)

**Definition** (Cantidad pivotal).  $Q(\tilde{X}, \theta)$  es cantidad pivotal si  $f_Q$  no depende de  $\theta$ .

e.g.  $(\bar{x} - \mu)/\sigma$  en familias de localización y escala.

**Proposition.** Sea  $A_\alpha : P(Q(\tilde{X}, \theta) \in A_\alpha) = 1 - \alpha$  entonces  $C_\alpha(\tilde{x}) = \{\theta : Q(\tilde{x}, \theta) \in A_\alpha\}$  es conjunto de confianza  $1 - \alpha$

**Proposition.**  $X_1, \dots, X_n \sim N(\mu, \sigma)$

$IC_{1-\alpha}(\mu) = [\bar{x}_n \mp z_{\alpha/2} \frac{\sigma}{\sqrt{n}}]$  si  $\sigma$  conocida

$IC_{1-\alpha}(\mu) = [\bar{x}_n \mp t_{n-1, \alpha/2} \frac{S_n}{\sqrt{n}}]$  si  $\sigma$  desconocida

$$IC_{1-\alpha}(\sigma^2) = \left[ \frac{(n-1)S_n^2}{\chi_{n-1, \alpha/2}^2}, \frac{(n-1)S_n^2}{\chi_{n-1, 1-\alpha/2}^2} \right]$$

**Definition** (Cant. pivotal asintótica).  $Q_n(\tilde{X}_n, \theta) \rightarrow_D Q$  e.g.

$$Q_n = \frac{T(\tilde{X}_n) - E_\theta^A(T(\tilde{X}_n))}{\sqrt{V_\theta^A(T(\tilde{X}_n))}} \rightarrow_D N(0, 1)$$

**Proposition.**  $\frac{\hat{\theta}_n - \theta}{se(\hat{\theta}_n)} \rightarrow_D N(0, 1) \Rightarrow [\hat{\theta}_n \mp z_{\alpha/2} se(\hat{\theta}_n)]$  intervalo de confianza  $(1 - \alpha)$  asintótico para  $\theta$

**Definition** (Intervalo EMV).  $[\hat{\theta}_n \mp z_{\alpha/2} \sqrt{(\hat{I}_n(\theta))^{-1}}]$

$$Q_n^{EMV} = \frac{\hat{\theta}_n - \theta}{\sqrt{(I_n(\theta))^{-1}}} \rightarrow_D Z \sim N(0, 1)$$

**Definition** (Función score).  $S_n = \frac{\partial}{\partial \theta} \log L$

$$Q_n^S = \frac{S_n}{\sqrt{I_n(\theta)}} \rightarrow_D Z \sim N(0, 1)$$

**Definition** (Precisión).  $\Delta$  es la mitad del intervalo

## 5 Contrastes de hipótesis

**Definition.**  $H_0$  hipótesis nula,  $H_1$  hipótesis alternativa

**Definition** (Contraste de hipótesis).  $\begin{cases} H_0 : F \in \mathcal{F}_0 \\ H_1 : F \in \mathcal{F}_1 \end{cases}$  es una función de decisión  $D : \mathcal{X}^n \rightarrow \{0, 1\}, \tilde{x} \mapsto D(\tilde{x})$

**Definition.**  $R$  región crítica tal que  $D(R) = 1$  (rechaza)

$\alpha = P(\text{error tipo I}) = P(X \in R | H_0 \text{ cierta})$  (significación)

$\eta = P(\text{error tipo II}) = P(X \notin R | H_0 \text{ falsa})$

**Definition** (Potencia del test).  $\beta = 1 - \eta$  probabilidad de decidir de forma acertada rechazar  $H_0$

**Definition** (p-valor). ínfimo de los  $\alpha$  para los cuales se rechazaría la hipótesis nula. Probabilidad de que, siendo  $H_0$  cierta, se observe otra muestra que sea al menos tan poco favorable a la hipótesis nula como la que se ha observado.

**Proposition.**  $p(\tilde{x}) = \sup_{\theta \in \Theta_0} P_{\theta}(T(\tilde{X}) \geq T(\tilde{x}))$

**Definition** (Función de potencia).

$$\beta(\theta) = P(X \in R) = \begin{cases} P(\text{Error tipo I}) & \text{si } \theta \in \Theta_1 \\ 1 - P(\text{Error tipo II}) & \text{si } \theta \in \Theta_2 \end{cases}$$

**Definition** (Nivel).  $\sup \beta(\theta) \leq \alpha$

**Theorem** (Neyman-Pearson).  $H_0 : \theta = \theta_0$  vs  $H_0 : \theta = \theta_1$ . Región crítica del contraste más potente de tamaño  $\alpha$ :

$$R = \left\{ \tilde{x} : \frac{L(\theta_1; \tilde{x})}{L(\theta_0; \tilde{x})} \geq A_{\alpha} \right\}$$

$$p\text{-valor} = P\left( \frac{L(\theta_1; \tilde{X})}{L(\theta_0; \tilde{X})} \geq \frac{L(\theta_1; \tilde{x})}{L(\theta_0; \tilde{x})} \right)$$

**Definition** (Uniformemente más potente de tamaño  $\alpha$ ).

$$\beta(\theta) \leq \alpha \quad \forall \theta \in \Theta_0, \quad \beta(\theta) \text{ máximo } \forall \theta \in \Theta_1$$

**Theorem** (Neyman-Pearson).  $H_0 : \theta = \theta_0$  vs  $H_0 : \theta \in \Theta_1$ . Si  $R(\theta_1)$  (del teorema anterior) no depende de  $\theta_1$ , la prueba estadística de  $R$  es UMP de tamaño  $\alpha$ .

**Proposition.**  $X \sim N(\mu, \sigma^2), \begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$

$$R = \{x : \bar{x} \geq B\}, \text{ con } B = \mu_0 + z_{\alpha} \frac{\sigma}{\sqrt{n}}$$

**Theorem.**  $f(x; \theta) = c(\theta)h(x)e^{\eta(\theta)t(x)}$  con  $\eta(\theta)$  creciente. El test de NP es UMP si  $H_1 : \theta > \theta_0$ .

**Definition** (Razón de verosimilitudes).

$$\lambda = \lambda(x) = \frac{\max_{\theta \in \Theta_0} L(\theta; x)}{\max_{\theta \in \Theta} L(\theta; x)} \Rightarrow R = \{x : \lambda(x) \leq A\}$$

**Theorem.**  $\begin{cases} H_0 : \theta \in \Theta_0 \\ H_1 : \theta \in \Theta_1 \end{cases}$

$$Q_n = -2 \log(\lambda(X_n)) \rightarrow_n \chi_d^2, \quad d = \dim(\Theta) - \dim(\Theta_0)$$

bajo la hipótesis nula

Dos tests para  $\begin{cases} H_0 : \theta = \theta_0 \\ H_1 : \theta \neq \theta_0 \end{cases}$

**Definition** (Test del Score).  $S_n(\theta; x_n) = \frac{\partial \log L}{\partial \theta}$

$$T_n^s(X_n) = \frac{S_n(\theta_0; X_n)^2}{I_n(\theta_0)}, \quad S_n(\theta_0; X_n) \approx N(0, I_n(\theta_0))$$

Rechaza  $H_0$  si  $T_n^s(x_n) > \chi_{1,\alpha}^2$

**Definition** (Test de Wald).  $\hat{\theta}_n \approx N(\theta_0, (I_n(\theta_0))^{-1})$

$$W_n = (\hat{\theta}_n - \theta_0)^2 I_n(\theta_0) \approx_{en H_0} \chi_1^2$$

Rechaza  $H_0$  si  $W_n^s(x_n) > \chi_{1,\alpha}^2$

## 6 Modelo lineal normal

**Definition** (Modelo teórico).  $y_i | x_i \sim N(\beta_0 + \beta_1 x_{1i} + \dots + \beta_{p-1} x_{(p-1)i}, \sigma^2)$ ,  $e_i = y_i - \hat{y}_i$ ,  $e_i, e_j$  son independientes  $\forall i, j$ .

Formulación matricial  $Y = X\beta + \epsilon$ :

$$Y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}, \epsilon = \begin{pmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{pmatrix}, X = \begin{pmatrix} 1 & x_{11} & \dots & x_{p-11} \\ \vdots & & & \vdots \\ 1 & x_{1n} & \dots & x_{p-1n} \end{pmatrix}$$

**Theorem** (Minimos cuadrados).  $b = (X^T X)^{-1} X^T Y$

Propiedades:  $\bar{e} = 0$  y pasa por  $(\hat{x}_1, \dots, \hat{x}_{p-1}, \hat{y})$

**Proposition.** Una variable explicativa

$$b_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad b_0 = \bar{y} - b_1 \bar{x}$$

**Proposition.** Con diferente varianza y  $V$  matriz diagonal de varianzas:

$$b = (X^T V^{-1} X)^{-1} X^T V^{-1} Y$$

**Definition** (ANOVA decomposition).  $SS_T = SS_R + SS_E$

$$SS_T = \sum (y_i - \bar{y})^2, SS_R = \sum (y_i - \hat{y}_i)^2, SS_E = \sum (\hat{y}_i - \bar{y})^2$$

$$s_E^2 = \frac{SS_E}{p-1}, \quad s_R^2 = \frac{SS_R}{n-p}, \quad F = \frac{s_E^2}{s_R^2}$$

$$\hat{\sigma}^2 = s_R^2$$

**Definition** (Coeficiente determinación).

$$R^2 = 100 \frac{SS_E}{SS_T} = 100(1 - \frac{SS_R}{SS_T}), R_{adj}^2 = 100(1 - \frac{s_R^2}{s_E^2})$$

**Proposition.**  $b|X \sim N(\beta, \sigma^2(X^T X)^{-1})$

**Proposition.** Una variable  $Cov(b_0, b_1 | x) = \frac{-\sigma^2 \bar{x}}{\sum (x_i - \bar{x})^2}$

$$b_0 | x \sim N(\beta_0, \frac{\sigma^2}{n} \frac{\sum x_i^2}{\sum (x_i - \bar{x})^2}), \quad b_1 | x \sim N(\beta_1, \frac{\sigma^2}{\sum (x_i - \bar{x})^2})$$

**Proposition.**  $s_R^2 | X \sim \frac{\sigma^2}{n-p} \chi_{n-p}^2$

**Proposition.**  $Var(b_j|x) = s_{b_j}^2$ ,  $t_j = b_j/s_{b_j}$

$$(b_j \mp t_{n-p}^{\alpha/2} s_{b_j}) \simeq (b_j \mp 2s_{b_j})$$

Si 0 en el intervalo, se puede quitar la variable del modelo

**Definition.**  $SS_{R0}$  suma sin las  $q$  variables a retirar

$$F = \frac{(SS_{R0} - SS_R)/q}{(SS_R)/(n-p)}, \quad \begin{cases} +F \Rightarrow \text{no retirar} \\ -F \Rightarrow \text{retirar} \end{cases}$$

Si se pueden retirar,  $F \sim F_{q,n-p}$ .

$F = s_e^2/s_R^2$  para comparar vs el modelo nulo,  $N(\bar{y}, \sigma^2)$ .

**Proposition.** Intervalo de confianza  $1 - \alpha$  de  $E(y|x_0)$

$$\left( \hat{y}(x_0) \pm t_{n-p}^{\alpha/2} s_R \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \right)$$

**Proposition.** Intervalo de predicción  $1 - \alpha$  de  $y(x_0)$

$$\left( \hat{y}(x_0) \pm t_{n-p}^{\alpha/2} s_R \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum (x_i - \bar{x})^2}} \right)$$

El intervalo de 95% podemos tener en cuenta  $t_{n-p}^{0.25} \approx 2$

Para más de una variable,  $\hat{y}(x_0) \sim N(E(y|x_0), \sigma^2 x_0'(X'X)^{-1}x_0)$   
son respectivamente

$$\left( \hat{y}(x_0) \pm t_{n-p}^{\alpha/2} s_R \sqrt{x_0'(X'X)^{-1}x_0} \right)$$

$$\left( \hat{y}(x_0) \pm t_{n-p}^{\alpha/2} s_R \sqrt{1 + x_0'(X'X)^{-1}x_0} \right)$$

Tipos de errores:

1. *Regular:*  $e_i = y_i - \hat{y}_i$ ,  $e = Y - \hat{Y} \sim N(0, \sigma^2(I - H))$   
 $H = X(X'X)^{-1}X'$  es la projection/hat matrix
2. *Standardized:*  $e_i^s = e_i/s_{e_i}$ . ( $s_{e_i}$  aproxima se) Si el modelo es correcto, 95% deberían estar en  $(-2, 2)$ .
3. *Deleted:*  $e_i^{sd} = (y_i - \hat{y}_{(i)})/s_{e_{(i)}}$ . Como los standardized, pero para la  $i$ -ésima predicción se hace un modelo con todos los datos excepto el  $i$ . No hace "trampas".

**Definition** (Distance in X-space).

$$H = X(X'X)^{-1}X', \quad h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum (x_i - \bar{x})^2}$$

If  $h_{ii} > 3p/n$ , the observation  $i$  is unusually far. (No indication by itself that model is wrong)

**Definition** (Degree of outlierness).  $|e_i^s|$

**Definition** (Influence on the fitted model). Se mide con la distancia de Cook:

$$DC_i = \frac{(\hat{Y} - \hat{Y}_{(i)})'(\hat{Y} - \hat{Y}_{(i)})}{s_R^2 p} = (e_i^s)^2 \frac{h_{ii}}{1 - h_{ii}} \frac{1}{p}$$

o con  $DFFIT_i = \hat{y}_i - \hat{y}_{(i)}$

Criterios para la selección de modelos:

1. Maximizar  $R_{adj}^2$
2. Minimizar  $C_p = \frac{SS_R}{s_R^2} + 2p - n$  donde  $s_R^2$  es la varianza residual del modelo con todas las variables.
3. Minimizar  $AIC = Const + n \log(SS_R) + 2p$ .
4. Minimizar  $BIC = Const + n \log(SS_R) + p \log(n)$ .

Tipos de cross validation:

Sirven para medir el rendimiento del modelo más "honestamente"

1. *One-shot:* Separar los datos en dos, uno para entrenar y el otro para medir. Barato pero poco fiable.
2. *Leave-one-out:* Para cada dato, predecirlo con un modelo entrenado con todos los otros datos.  $PRESS = SS_R^{l.one.out} = \sum_i (e_i^d)^2$ . Muy costoso, pero fiable.
3. *Leave-p-out:* Para cada subconjunto de  $p$  datos, predecirlo con un modelo entrenado con los otros. Aún más costoso y fiable.
4. *k-fold:* Separar en  $k$  grupos del mismo tamaño y predecir cada uno con un modelo entrenado con los otros.  $SS_R^{k.fold} = \sum_{i=1}^n (y_i - \hat{y}_{(i)}^{k.fold})^2$ ,  $R_{k.fold}^2 = 100(1 - SS_R^{k.fold}/SS_T)$ . Es el bueno.

Si hay alguna categórica, con  $k$  posibles categorías, se añaden  $k - 1$  variables indicadoras (una es la *baseline*) y en el modelo se ponen estas indicadoras y el producto de las indicadoras por las variables continuas. Después se intenta simplificar el modelo con los estadísticos  $t$  y  $F$ .

## 7 Modelo de respuesta categórica

Queremos hacer un modelo para una variable binaria  $y$  que dependa de variables continuas  $x_i$ .

En nuestros datos, tenemos  $n_i$  experimentos con las explicatorias  $x_i$ , de los cuales  $y_i$  han sido *si*, y  $n_i - y_i$  *no*.

**Definition** (Modelo teórico).  $y_i|x_i \sim Bin(n_i, \pi(x_i))$

$$\pi(x_i) = \frac{e^{\beta_0 + \beta_1 x_{1i} + \dots + \beta_{p-1} x_{(p-1)i}}}{1 + e^{\beta_0 + \beta_1 x_{1i} + \dots + \beta_{p-1} x_{(p-1)i}}}$$

$$\log \frac{\pi(x_i)}{1 - \pi(x_i)} = \log Odds(x_i) = \beta_0 + \beta_1 x_{1i} + \dots + \beta_{p-1} x_{(p-1)i}$$

Se entrena minimizando el *Pearson statistic* (que da menos importancias a los cercanos a 0 o 1):

$$X^2(Y, \hat{Y}) = \sum_{i=1}^n \frac{(y_i - n_i \hat{\pi}(x_i))^2}{n_i \hat{\pi}(x_i) (1 - \hat{\pi}(x_i))} = \sum_{i=1}^n (e_i^P)^2$$

o la *deviance* ( $\approx SS_R$  en modelos lineales):  $ResDev =$

$$2 \sum_{i=1}^n \left( y_i \log \frac{y_i}{n_i \hat{\pi}(x_i)} + (n_i - y_i) \log \frac{n_i - y_i}{n_i (1 - \hat{\pi}(x_i))} \right) = \sum_{i=1}^n (e_i^D)^2$$

Si el modelo es correcto,  $ResDev \sim \chi_{n-p}^2$  y el 95% de los  $e_i^D$  deberían estar en  $(-2, 2)$ .

## 8 Miscelánea

### Propiedades de la distribución Gamma

Parametrización con scale  $\theta$

$$f(x) = \frac{1}{\Gamma(\alpha)\theta^\alpha} x^{\alpha-1} e^{-x/\theta}, \quad E(X) = \alpha\theta, \quad Var(X) = \alpha\theta^2$$

$$\Gamma(\alpha_1, \theta) + \Gamma(\alpha_2, \theta) \sim \Gamma(\alpha_1 + \alpha_2, \theta), \quad c\Gamma(\alpha, \theta) \sim \Gamma(\alpha, c\theta)$$

$$X \sim \Gamma(\alpha, scale = \theta) \Rightarrow \frac{2}{\theta}X \sim \chi_{2\alpha}^2$$

### Parametrización con rate $\beta$

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad E(X) = \frac{\alpha}{\beta}, \quad Var(X) = \frac{\alpha}{\beta^2}$$

$$\Gamma(\alpha_1, \beta) + \Gamma(\alpha_2, \beta) \sim \Gamma(\alpha_1 + \alpha_2, \beta), \quad c\Gamma(\alpha, \beta) \sim \Gamma(\alpha, \frac{\beta}{c})$$

$$X \sim \Gamma(\alpha, rate = \beta) \Rightarrow 2\beta X \sim \chi_{2\alpha}^2$$

$$\sum_0^\infty nx^{n-1} = \frac{1}{(1-x)^2}$$

$$\Gamma(n) = (n-1)!, \quad B(a, b) = \int_0^1 t^{a-1}(1-t)^{b-1} dt = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

$$aN(\mu, \sigma^2) + b \sim N(a\mu + b, (a\sigma)^2)$$

$$aN(\mu_1, \sigma_1^2) + bN(\mu_2, \sigma_2^2) = N(a\mu_1 + b\mu_2, (a\sigma_1)^2 + (b\sigma_2)^2)$$

$$X \sim Weibull(\alpha, \beta) \Rightarrow X^\alpha/\beta \sim Exp(1)$$